

# introduction

☼ 상태	Done
👤 작성자	🕒 김민준
🕒 최종 편집 일시	@2023년 11월 27일 오전 3:41
☰ 태그	

## 1. introduction

레이블이 알려진 예제들의 데이터셋을 기반으로 알려지지 않은 레이블을 예측하려고 시도하는 것으로, 이는 지도 학습(supervised learning)으로 기계 학습의 종류 중 하나이다. 다른 다양한 종류의 문제를 탐구하기 전에, 어떤 종류의 기계 학습 문제를 다루더라도 따라다니는 핵심 구성 요소에 대해 알아보자.

### 1. 학습할 수 있는 데이터

데이터는 기계 학습과 데이터 과학에서 핵심적인 역할을 한다. 데이터셋은 예제들의 모음으로, 각 예제는 특징(feature)과 레이블(label)로 구성된다. 특징은 모델이 예측에 사용하는 입력 데이터의 속성들을 나타내며, 레이블은 모델이 예측해야 하는 특별한 속성으로, 지도 학습에서 예측하려는 값을 나타낸다.

일반적으로, 고정된 길이 벡터로 표현되는 고정된 입력값은 모델 학습에서 편리하지만, 모든 데이터가 이런 식으로 표현되기는 어려울 수 있다. 이미지나 텍스트와 같은 가변 길이 데이터는 딥 러닝과 같은 현대적인 기계 학습 모델이 처리하는데 더 나은 유연성을 제공한다.

많은 데이터가 있는 경우 모델 학습이 용이해지며, 이는 현대 딥 러닝의 성공에 기여한다. 그러나 적절하지 않거나 오류가 많은 데이터는 모델의 학습을 방해할 수 있고, 때로는 사회적 편견이나 공정성 문제를 반영할 수 있다. 따라서 적절하고 품질 좋은 데이터가 중요합니다.

결국, 데이터는 기계 학습 및 데이터 과학에서 핵심적인 구성 요소로, 올바른 데이터를 가지고 올바르게 처리하면 모델의 성능을 높일 수 있다.

### 2. 데이터를 변환하는 방법에 대한 모델

기계 학습은 주로 데이터를 다양한 방식으로 변환하는 과정을 포함한다. 이 변환은 사진을 분석하여 사람의 웃음 정도를 예측하거나 센서 데이터를 이용하여 정상 또는 비정상 여부를 예측하는 등 다양한 예측 작업에 활용될 수 있다. 모델은 데이터를 처리하고 예측을 수행하는 계산적 도구를 의미합니다.

### 3. 모델의 성능을 측정하는 목적 함수

기계 학습에서 모델을 향상시키는 과정에서 우리는 모델의 개선이 무엇을 의미하는지를 명확하게 정의해야 한다. 모델의 성능을 평가하기 위한 형식적인 척도로 목적 함수(Objective Functions)가 사용된다. 이러한 함수는 일반적으로 낮을수록 더 나은 성능을 의미한다. 예를 들어, 수치 값 예측에 대해 가장 많이 사용되는 목적 함수는 제곱 오차(Squared Error)이다. 이는 예측 값과 실제 값 사이의 차이의 제곱을 의미한다. 또한, 분류 작업에서는 오류율을 최소화하는 것이 일반적인 목표이다. 즉, 예측이 실제 값과 다른 비율을 낮추는 것을 말한다.

모델을 훈련시키는 동안에는 손실 함수를 모델의 매개변수에 대한 함수로 취급하고, 훈련 데이터셋을 사용하여 손실을 최소화하여 모델의 최적 매개변수를 학습한다. 그러나 훈련 데이터에 대한 우수한 성능이 실제로는 보이지 않는 데이터에 대해서도 반드시 좋은 성능을 내지는 않는다. 따라서 우리는 훈련 데이터와 별도로 보류된 평가용 데이터셋을 사용하여 모델의 일반화 성능을 평가한다. 훈련 데이터에만 맞추어져 있어서 실제 데이터에서는 성능이 나오지 않는 현상을 '과적합(Overfitting)'이라고 한다.

이런 일반화 문제를 해결하기 위해 더 나은 모델을 개발하고, 실제로 보이지 않는 데이터에서도 효과적으로 예측할 수 있는 모델을 구축하는 것이 기계 학습의 주요 목표 중 하나이다.

#### 4. 목적함수를 최적화 하기위해 모델 파라미터를 조정하는 알고리즘

기계 학습에서 데이터 소스와 표현, 모델, 목적 함수를 확보했다면, 손실 함수를 최소화하기 위한 최적의 매개변수를 탐색할 수 있는 알고리즘이 필요하다. 딥 러닝에서 인기 있는 최적화 알고리즘은 경사 하강법(Gradient Descent)이라는 접근 방식을 기반으로 한다. 이 방법은 각 단계에서 각 매개변수에 대해 조금씩 변화시켰을 때 훈련 세트의 손실이 어떻게 변하는지를 확인한다. 그리고 그 결과에 따라 손실을 낮추는 방향으로 매개변수를 업데이트하는 방향으로 최적화한다.

## 머신러닝 문제의 종류

### 1. 지도학습

지도 학습은 데이터셋에 입력 특징과 라벨이 함께 포함되어 있어, 이를 활용하여 모델을 훈련시키고, 입력 특징을 기반으로 라벨을 예측하는 방법이다. 각 입력 특징과 그에 상응하는 라벨을 쌍으로 갖는 것을 예시라고 한다. 이 방법은 다양한 산업 분야에서 사용되며, 많은 중요한 작업들을 수행하는 데 사용이 된다.

지도 학습에서 모델은 주어진 입력을 바탕으로 특정한 라벨을 예측하는 방법을 학습하는데 예를 들어, 의료 분야에서는 환자의 의료 데이터(입력)와 그에 따른 질병 여부(라벨)를 포함한 데이터셋으로부터 질병을 예측하는 모델을 학습할 수 있다. 이런 예측은 입력 데이터에 기초해 어떤 결과가 예상되는지를 알려주므로, 의사의 결정을 도와주거나 또는 예측을 하기 위해 활용될 수 있다.

지도 학습은 다양한 형태를 가지며, 입력과 출력의 유형, 데이터 크기, 목표 등에 따라 다양한 모델링 결정이 필요하다. 이 과정에서는 데이터셋을 학습용과 테스트용으로 나누어 일반화

성능을 평가하며, 모델이 처음 보는 데이터에 대해서도 잘 동작하는지 확인한다.

전반적으로, 지도 학습은 데이터셋을 활용하여 모델을 학습하고, 이를 통해 라벨이 알려지지 않은 새로운 입력에 대한 예측을 수행하는 프로세스를 의미한다.

## 2. 비지도 학습 및 자기지도학습

비지도 학습은 데이터에서 레이블이 없는 상태에서 특징을 발견하거나 데이터의 구조를 이해하기 위해 사용된다. 이를 통해 데이터의 패턴, 클러스터, 특징 등을 찾을 수 있다. 비지도 학습의 예로는 클러스터링, 차원 축소, 밀도 추정, 패턴 인식 등이 있다.

클러스터링은 유사한 속성을 가진 데이터 그룹을 식별하는 기술로, 예를 들어 사진을 개, 고양이, 풍경 등의 그룹으로 분류를 하는 것이다. 차원 축소는 데이터의 특징을 보다 간결하게 표현하기 위해 데이터의 차원을 줄이는 방법이다. 주성분 분석(PCA)은 데이터의 주요 특성을 나타내는 주성분을 찾아내어 데이터를 변환한다.

또한, 심층 생성 모델은 데이터의 밀도를 추정하는 데 사용되는데 이 모델은 데이터 생성을 위한 확률 분포를 학습하고, 새로운 데이터를 생성하거나 데이터의 가능성에 대해서도 평가할 수 있다. 자기 지도 학습은 레이블이 없는 데이터에서 일부 감독 정보를 활용하여 학습하는 기법이다. 텍스트나 이미지에서 누락된 부분을 채우거나, 두 영역 간의 관계를 학습하는 등의 방식으로 이루어진다.

이러한 비지도 학습 기술은 데이터로부터 숨겨진 패턴을 발견하거나 새로운 표현을 학습함으로써 데이터 과학 및 기계 학습 분야에서 중요한 도구로 활용되고 있다.

## 3. 환경과 상호작용

지금까지는 머신 러닝에서 데이터의 원래 출처나 모델이 결과를 생성하는 방식에 대해 다루지 않았다. 왜냐하면 지도 및 비지도 학습은 환경과의 상호작용에 대해 다루지 않기 때문이다. 이들은 처음에 데이터를 모으고 패턴 인식 모델을 사용하여 학습하는 접근 방식으로, 환경과의 상호작용 없이 학습인 오프라인 학습을 한다. 그러나 현실에서는 지능형 에이전트를 생각해야 한다. 이것은 단순한 예측 뿐만 아니라 행동도 선택할 수 있어야 해서 오프라인 학습은 부적절한데 환경과의 상호작용을 고려하는 것은 머신 러닝에 새로운 모델링 문제를 만들어내었다.

예를 들어, 환경의 메모리, 의도, 그리고 동적인 특성을 고려해야 한다. 이러한 상호작용은 분포 이동 문제를 일으킬 수 있는데 이 문제는 훈련과 테스트 데이터가 다른 경우, 즉 다른 분포를 가질 때 발생한다. 이러한 상호작용을 다루기 위해 강화학습이라는 프레임워크가 등장했다. 이 프레임워크는 에이전트가 환경과 상호작용하며 행동에 따라 보상이나 벌점을 받아 학습하는 방식으로 지능적인 에이전트를 훈련시킨다.

## 4. 강화학습

강화학습은 에이전트가 환경과 상호작용하며 행동을 취하는 프레임워크이다. 에이전트는 환경으로부터 관찰을 받고, 이를 기반으로 행동을 선택하며, 이로부터 보상을 받는다. 이러한

행동의 결과로 얻는 보상은 행동 평가와 학습에 중요한 역할을 한다. 강화학습은 지도학습과 달리 정확한 레이블이나 지도 정보 없이 보상만을 이용해 학습을 진행한다.

강화학습은 지도학습과 달리 미래에 어떤 행동이 좋은 결과를 가져올지 확신할 수 없는 상황에서 학습을 진행해야 한다. 이를 위해 강화학습은 시간이 지남에 따라 에이전트가 어떤 행동을 취할지 결정하는 방법을 학습하고 개선하는 과정을 가진다.

이러한 프로세스는 시간에 따라 정책이라고 불리는 함수를 발전시키는 것인데, 정책은 환경의 관찰을 받아 어떤 행동을 선택할지를 결정한다. 강화학습의 목표는 최적의 선택을 찾는 것이며, 이를 통해 에이전트가 가장 많은 보상을 얻을 수 있도록 하는 것이다.

강화학습은 이론적으로 매우 일반적이며, 다양한 응용 분야에서 활용될 수 있다. 예를 들어, 딥러닝을 활용한 강화학습은 알파고의 승리나 비디오 게임에서 높은 성능을 보이는 것과 같은 좋은 결과를 만들어 내고 있다.

이와 함께, 강화학습은 보상의 타이밍, 환경 변화에 대응하는 능력, 불완전한 정보로부터의 학습, 미래의 더 나은 전략 탐색 등 다양한 어려운 문제를 다뤄야 한다. 이러한 문제들은 학습을 더 복잡하게 만들지만, 실제 상황에서 발생할 수 있는 다양한 문제를 모델링하고 해결하는데 도움이 된다.